

딥러닝 기반 지능형 측정

CMM의 방법 및 시스템

젠잉 청, 위안 선, 강 후, 지에 리, 티엔 푸 루, 루이 준 리

초록

생산 라인에서 3차원 측정기(CMM)를 검사에 사용할 때 일반적으로 많은 수작업 개입과 관리가 필요해 효율성이 떨어집니다. 이 연구에서는 일반적인 부품의 일반적인 특징(구멍, 실린더, 볼, 계단, 슬롯 등)을 측정하는 딥러닝 기반 지능형 측정 방법과 시스템을 제시하여 검사 효율성을 향상시킵니다. 이 방법은 비전 센서와 트리거 프로브를 결합합니다. 특징을 학습하고 지능적으로 감지하기 위해 You Only Look Once 알고리즘이 사용되었습니다. 이미지 역원근 변환을 기반으로 한 이미지 매칭 알고리즘을 설계하고 개미 군집 알고리즘을 구현하여 측정 순서를 최적화했습니다. 그런 다음 특징 측정 경로 계획을 위한 자동 접근 방식을 설계했습니다. 제시된 시스템을 CMM을 사용하여 테스트하고 여러 개의 전형적인 특징을 가진 부품을 측정했습니다. 그 결과 이 방법과 시스템이 일반적인 특징의 지능적인 측정을 위해 효과적으로 구현될 수 있음을 보여주었습니다.

색인 용어: CMM, 지능형 측정, 협력 센서 구성

감사

이 연구는 중국 국립자연과학재단(52175506, 52075143)의 일부 지원으로 진행되었습니다.

교신저자: 루이준 리(이메일: rj-li@hfut.edu.cn).

딥러닝 기반 지능형 측정

중국 허페이 230009 **CMM의 방법 및 시스템** 광전자 공학부에 소속된

Zhen-Ying Cheng, Yuan Sun, Kang Hu, Jie Li 및 Rui-Jun Li(이메일: rj-li@hfut.edu.cn)가 있습니다. Tien-Fu Lu는 호주 애들레이드 대학교 기계공학부(SA 5005, 호주)에 있습니다(이메일: tien-fu.lu@adelaide.edu.au).

딥러닝 기반 지능형 측정

CMM의 방법 및 시스템

초록

생산 라인에서 3차원 측정기(CMM)를 검사에 사용할 때 일반적으로 많은 수작업 개입과 관리가 필요해 효율성이 떨어집니다. 이 연구에서는 일반적인 부품의 일반적인 특징(구멍, 실린더, 볼, 계단, 슬롯 등)을 측정하는 딥러닝 기반 지능형 측정 방법과 시스템을 제시하여 검사 효율성을 향상시킵니다. 이 방법은 비전 센서와 트리거 프로브를 결합합니다. 특징을 학습하고 지능적으로 감지하기 위해 You Only Look Once 알고리즘이 사용되었습니다. 이미지 역원근 변환을 기반으로 한 이미지 매칭 알고리즘을 설계하고 개미 군집 알고리즘을 구현하여 측정 순서를 최적화했습니다. 그런 다음 특징 측정 경로 계획을 위한 자동 접근 방식을 설계했습니다. 제시된 시스템을 CMM을 사용하여 테스트하고 여러 개의 전형적인 특징을 가진 부품을 측정했습니다. 그 결과 이 방법과 시스템이 일반적인 특징의 지능적인 측정을 위해 효과적으로 구현될 수 있음을 보여주었습니다.

색인 용어: CMM, 지능형 측정, 협력 센서 구성

1. 소개

항공우주, 전자, 자동차 및 기타 제조 분야의 고속 발전에 따라 기계 부품의 높은 제조 정확도에 대한 요구가 계속 증가하고 있습니다. 이러한 부품의 주요 특징을 측정하는 것은 제조 정확도 검사에서 중요한 부분입니다. 3차원 측정기(CMM)는 높은 정확도로 인해 가장 널리 사용되는 측정 기기가 되었습니다. 그러나 수동으로 프로그래

딥러닝 기반 지능형 측정

명하는 측정 방식으로는 **CMM의 방법 및 시스템**을 대체할 수 없습니다. 따라서

측정 과정에서 사람의 개입과 관리를 최소화하고 지능적인 의사결정을 내릴 수 있도

록 하는 연구가 시급한 과제가 되었습니다.

컴퓨터 지원 설계(CAD) 모델을 사용하여 부품 측정을 안내하는 컴퓨터 지원 공

정 계획 기법이 널리 연구되고 있습니다. 이러한

검사 정보의 지능적 추출[1-3], 샘플링 전략, 검사 경로 계획[4] 등의 기술이 있습니다.

이러한 기법들은 수작업에 대한 의존도를 줄였습니다. 그러나 CAD 모델을 CMM의 기계 좌표계와 정렬하려면 여전히 상당한 수동 입력이 필요하며 모든 구성 요소에 대해 정확한 CAD 모델을 항상 사용할 수 있는 것은 아닙니다. 따라서 일부 연구에서는 CMM에 여러 센서를 통합하여 CAD 모델에 의존하지 않는 측정 방법을 개발했으며, 이는 센서 구성에 따라 보완, 경쟁, 협력 시스템으로 분류됩니다 [5].

보완 센서 구성에서 센서는 서로 직접적으로 의존하지는 않지만 구성 요소에 대한 완전한 정보를 제공하기 위해 결합할 수 있습니다. 브래들리 등[6]은 레이저 스캐너와 트리거 프로브를 결합한 보완 센서 측정 방법을 제안했습니다. 레이저 스캐너는 자유형 표면에 필요한 고밀도 3차원(3D) 포인트를 제공하고 트리거 프로브는 패치의 경계를 정확하게 정의합니다. Zhao 등[7]은 트리거 프로브와 레이저 스캐너를 결합하여 CMM의 검사 계획을 자동으로 생성하는 방법을 제안했습니다. 검사할 각 피처에 적합한 센서를 선택하기 위해 지식 기반 센서 선택 방법을 구현했습니다. 또한 개발된 검사 계획 모듈은 측정 전략을 자동으로 계획했습니다. 위에서 설명한 상호 보완적인 센서 시스템은 완전한 부품 정보를 산출합니다. 그러나 서로 다른 센서의 데이터가 단순히 최종 디지털화된 결과와 동일한 좌표계로 통합되기 때문에 측정 정확도가 제한됩니다 [9].

경쟁 센서 구성은 각 센서가 동일하게 측정한다는 의미입니다.

기능을 독립적으로 사용하여 측정 불확실성을 줄이고 잘못된 측정을 방지합니다.

Huang 등[8]은 트리거 프로브와 에어리어 레이저 스캐너를 사용한 동적 감지 모델링

접근법을 제안했습니다. 먼저 레이저 스캐너를 사용하여 부품을 스캔하여 전체 모양을 캡처한 다음 트리거 프로브를 사용하여 측정합니다. 마지막으로 칼만 필터를 사용하여 표면 모델을 점진적으로 업데이트하여 트리거 프로브 데이터를 융합합니다. Yu 등[9]은 광학 스캐너를 사용하여 좌표 데이터를 수집한 다음 지능형 특징 인식 및 분할 알고리즘을 사용하여 부품의 전체 표면 정보를 추출하여 트리거 프로브가 각 특징을 다시 측정하도록 안내했습니다.

측정 결과는 스캔한 데이터를 보정하는 데 사용되었습니다. 위의 경쟁 센서 시스템은 전체 구성 요소를 여러 번 반복적으로 측정한 다음 데이터 융합을 사용하여 결과를 업데이트합니다. 이러한 경쟁 센서 시스템은 상호 보완적인 센서 구성보다 정확도가 향상되지만 반복 측정으로 인해 시스템의 효율성이 떨어집니다.

협력 센서 구성에서는 센서 간에 정보 상호 작용, 즉 한 센서에서 얻은 정보가 다른 센서의 측정을 안내하는 데 사용됩니다. Lu 등[10]은 접촉 스캐닝과 포인트 레이저 프로브를 통합하는 다중 센서 접근 방식을 제안했습니다. 포인트 레이저 프로브는 선험적 경로 정보를 획득하고, 이후 계획된 경로를 사용하여 접촉 스캐닝 프로브를 안내하여 복잡한 표면을 빠르고 정확하게 디지털화합니다. 우리 그룹 [11]은 스테레오 비전과 트리거 프로브를 결합한 자동화된 딥홀 측정 시스템을 제안했습니다. 장정유 보정 방법을 사용하여 카메라를 보정하고 스테레오 비전 알고리즘을 사용하여 프로브와 딥홀의 공간 위치를 결정하며 트리거 프로브가 위치 정보를 사용하여 딥홀을 측정하도록 유도합니다. 카메라 위치가 변경되면 보정된 카메라의 계수를 다시 사용해야 하며, 보정 과정과 좌표계 변환 작업이 복잡합니다. 그런 다음 복잡한 보정 단계를 없애는 새로운 광학 구조를 사용하여 자체 보정 고정밀 비전 방법을 제안합니다 [12]. 이 방법은 프로브 팁을 직경 100 μm 미만의 미세 구멍으로 안내할 수 있습니다. 그러나 구성 요소의 전반적인 지능형 측정은 아직 달성되지 않았습니다.

이 연구는 다음을 결합하여 CMM을 위한 지능형 측정 시스템을 제안합니다. 비전 센서와 터치 트리거 프로브를 사용하여 그룹의 이전 연구를 기반으로 구성 요소의 일반적인 특징을 지능적으로 측정할 수 있습니다. 이 시스템은 협력 센서 구성, 비

전 센서로 구성 요소 이미지를 캡처하고 딥러닝 기반 지능형 알고리즘을 사용하여 구성 요소의 특징에 대한 정보를 추출합니다. 그런 다음 프로브 측정을 위한 경로와 샘플링 전략이 계획됩니다. 이 시스템은 구조가 간단하고 CAD 모델과 복잡한 카메라 보정이 필요하지 않으며, 높은 정확도로 프로브를 트리거하여 최종 결과를 얻을 수 있습니다.

데이터 융합과 반복 측정의 불편함 없이 측정 정확도를 높일 수 있습니다. 본 백서의 구성은 다음과 같습니다: 섹션 2에서는 지능형 측정 시스템의 설계를 소개합니다. 섹션 3에서는 지능형 방법의 작동 원리에 대해 설명합니다. 섹션 4에서는 실험과 분석에 대해 설명합니다. 섹션 5에서는 연구를 마무리합니다.

2. 측정 시스템 설계

2.1 측정 시스템 구성




그림 1 CMM 지능형 측정 시스템의 일반 프레임워크

그림 1은 CMM 지능형 측정 시스템의 일반적인 프레임워크를 보여줍니다[12].

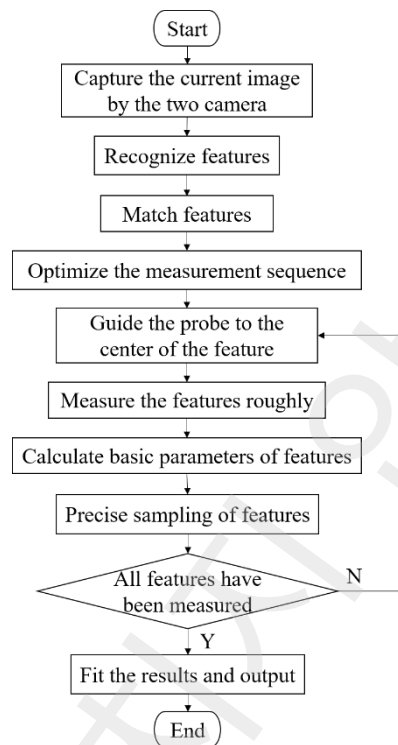
이 시스템은 주로 트리거 프로브, 산업용 카메라 두 대, 광원, 광학 조정 브래킷, 지능형 측정 소프트웨어가 장착된 CMM으로 구성됩니다. 트리거 프로브는 부품 표면의 좌표 점을 획득하는 데 사용됩니다. 두 대의 산업용 카메라가 광학 조정 브래킷에 장착되어 있으며, CMM의 전면과 우측에 배치되어 부품과 프로브의 이미지를 캡처합니다. 광원은 시스템에 밝기를 제공합니다. 지능형 측정 소프트웨어는 광학 및 기계 센서의 정보를 처리하고 트리거 프로브가 부품을 측정하도록 안내합니다.

2.2 측정 시스템의 워크플로

측정을 시작하기 전에 트리거 프로브와 구성 요소가 카메라 시야에 동시에 선명

하게 나타나야 합니다. 그렇지 않으면 조건이 충족될 때까지 카메라 각도나 트리거 프로브 위치를 조정해야 합니다. 일반적인

그런 다음 그림 2와 같이 워크플로와 함께 지능형 측정 시스템을 사용하여 구성 요소의



특징을 지능적으로 측정합니다.

그림 2 지능형 계측 시스템의 워크플로우 다이어그램

3. 방법의 원리

3.1 특징 감지

지능형 측정을 실현하려면 먼저 산업용 카메라로 촬영한 이미지에서 측정할 피처를 검출하는 작업, 즉 목표물 검출이 필요합니다. 표적 검출은 전통적인 표적 검출 알고리즘과 딥러닝 기반 표적 검출 알고리즘으로 나뉩니다. 기존 알고리즘은 시스템 리소스 오버헤드가 크고 알고리즘의 성능을 보장하기 위해 규칙과 다양한 제한 매개변수를 설정해야 합니다. 또한 알고리즘 성능의 안정성이 떨어집니다. 이에 반해 딥러닝 기반 알고리즘은 데이터 기반 접근 방식을 통해 자율 학습을 실현하고 일반화 능력이 뛰어납니다. YOLO(You Only Look Once)는 탐지 정확도와 탐지 속도 측면에서 좋은

결과를 얻을 수 있는 단일 단계 딥러닝 표적 탐지 알고리즘입니다. 이 알고리즘은 표적 탐지 작업을 로컬라이제이션과 분류의 회귀 문제로 처리하며, 표적의 로컬라이제이션과 분류 확률은 다음과 같이 구합니다.

입력 이미지를 직접 예측하는 엔드투엔드 컨볼루션 신경망[13]을 사용합니다. 이 연구에 사용된 YOLOv5 알고리즘은 모델 크기가 작고, 구축 비용이 저렴하며, 유연성이 좋고, 탐지 속도가 빠르다는 장점이 있습니다. 그림 3은 입력, 백본, 목, 머리[15]의 네 가지 주요 부분으로 구성된 네트워크 모델 구조[14]를 보여줍니다.

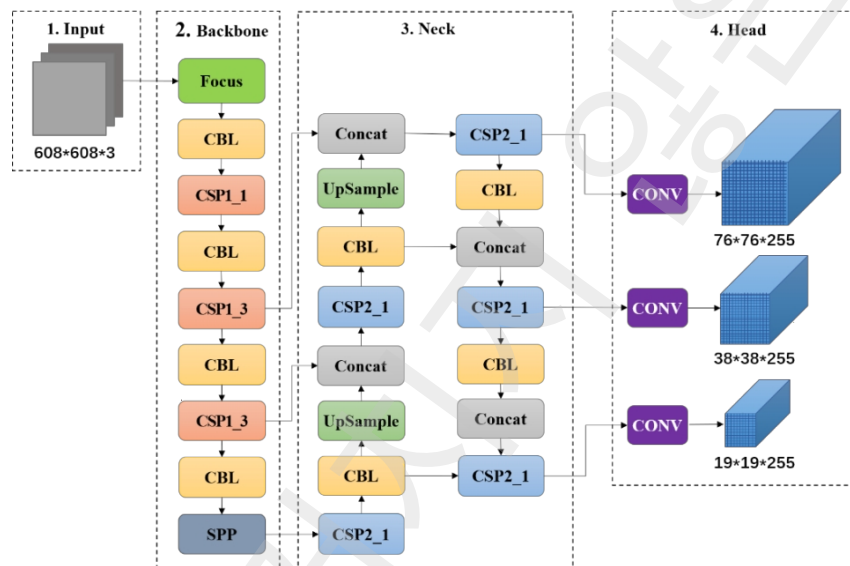


그림 3 YOLOv5의 네트워크 구조

크기/모양 변경, 배치 위치 변경, 로컬 오클루전, 표면 재질 변경 등의 상황에서도 부품의 일반적인 특징을 정확하게 인식할 수 있도록 하기 위해 일반적인 특징 데이터 세트에 대한 요구사항은 다음과 같습니다:

- (1) 데이터 세트의 이미지 개수는 학습에 필요한 개수를 충족해야 하며, 최소 2000개 이상이어야 합니다.
- (2) 데이터 세트의 사진에는 다양한 각도, 다양한 위치, 로컬 오클루전이 있는 특수한 경우의 컴포넌트가 포함되어 있습니다.
- (3) 컴포넌트 샘플은 서로 다른 표면 텍스처와 일반적인 피쳐 분포의 유형과 수가 다릅니다.

(4) 기능의 레이블과 위치 프레임은 소프트웨어를 사용하여 레이블을 지정합니다.

이 연구에서는 산업용 카메라를 사용하여 *프로브*, *구멍*, *실린더*, *슬롯*, *씨슬롯*, *스텝*, *볼*의 7가지 카테고리를 포함한 일반적인 특징을 가진 부품의 사진 2050장을 데이터 세트로 촬영했습니다. *프로브*는 프로브, *홀은 홀*, *실린더*는 실린더를 의미합니다,

슬롯은 정사각형 슬롯을 의미하고, cslot은 원형 호가 있는 슬롯을 의미하며, 단계는 정사각형 탭을 의미합니다.

공은 공을 나타냅니다. 데이터 세트는 PASCAL VOC 형식이며, 이미지의 타킷은 LabelImg를 사용하여 레이블이 지정됩니다.

표 1. 데이터 향상을 위한 하이퍼파라미터 설정		
방법	원리	하이퍼파라미터
모자이크	네 개의 이미지를 무작위로 자른 다음 하나의 이미지에 스티칭합니다. 이미지	0.8
fliplr	이미지의 무작위 수평 뒤집기 변환	0.4
flipud	이미지의 무작위 수직 플립 변환	0.2
hsv_h	이미지 색조의 색조 변화	0.015
hsv_s	채도의 이미지 색상 변화	0.7
hsv_v	이미지 색상 값의 변화	0.4
shear	이미지의 무작위 아핀 변환	8.0
규모	이미지의 무작위 크기 조정	0.6

데이터 향상 기법은 사용 가능한 데이터 세트의 수가 적기 때문에 측정 환경 조명 변화와 부품 크기 변화에 대한 훈련 데이터를 늘리고 훈련 시나리오를 강화하는 데 사용됩니다. 표 1은 데이터 강화 기법의 사용 방법과 원리를 보여줍니다. 데이터 강화의 변환 계수는 10으로 설정하고, 증강된 데이터 세트는 총 20500개의 이미지입니다. 데이터 세트는 8:2의 비율에 따라 훈련 세트와 검증 세트로 무작위로 나뉘며, 훈련 세트의 최종 이미지 수는 16400개입니다. 또한 검증 세트의 이미지 수는 4100개입니다. 모델 학습은 800회마다 하나의 모델을 생성합니다. 이 중 mAP 값이 가장 높은 모델을 전체 성능이 가장 우수한 모델로 선택합니다. 그런 다음 모델의 각 하이퍼파라미터를 조정하여 정확도와 회상률의 균형을 맞춰 특징 검출 정확도를 만족하는 최적의 모델

가중치를 찾습니다. 표 2와 3은 학습 구성과 하이퍼파라미터 설정을 보여줍니다.


표 2 교육을 위한 컴퓨팅 리소스 구성 이름 구성

시스템	Windows10
CPU인텔 코어 i7-12700	
GPU	NVIDIA GeForce RTX 3080
솔리드 스테이트 드라이브	500GB
파이썬	Python3.6
CUDA	CUDA11.3
파이토치	PyTorch1.7
OpenCV	OpenCV4.3.2

주요 훈련 하이퍼파라미터 설정			
이름	의미	하이퍼파라미터	
이미지 크기	트레이닝의 이미지 크기 설정	800*800*3	
에포크트레이닝당 배치	크기최대 허용 배치 크기	8	800
	하드웨어		
옵티마이저	옵티마이저의 종류	SGD	
모멘텀	속도 모멘텀	0.937	
	lr0초기 학습률	0.01	
	lrf학습률 계수	0.1	
워밍업	반복 워밍업 학습 시대	3	


그림 4(a)는 훈련 및 검증 세트의 손실 함수 곡선을 보여줍니다. 바운딩 박스 회귀, 목적 회귀, 분류 회귀의 손실이 기본 평활도로 감소합니다. 또한 검증 세트의 손실이 관찰되며 과적합이 발생하지 않습니다. 그림 4(b)는 검증 집합의 정밀도와 재현률의 변동 곡선을 보여줍니다. 곡선의 변동폭이 작아 훈련 효과가 좋다는 것을 알 수 있습니다. 그림 5는 각 카테고리의 PR 곡선을 보여줍니다. 모든 클래스의 mAP가 0.984 이상

이며, 각 카테고리의 PR 곡선 면적이 1에 가까워 모델의 탐지율이 높다는 것을 알 수



있습니다.

(a) 학습 및 검증 세트의 손실 함수 곡선



(b) 검증 세트의 정확도, 회수율 및 mAP의 변동 곡선 그림 4 학습 과정

의 손실 변동 및 평가 지표

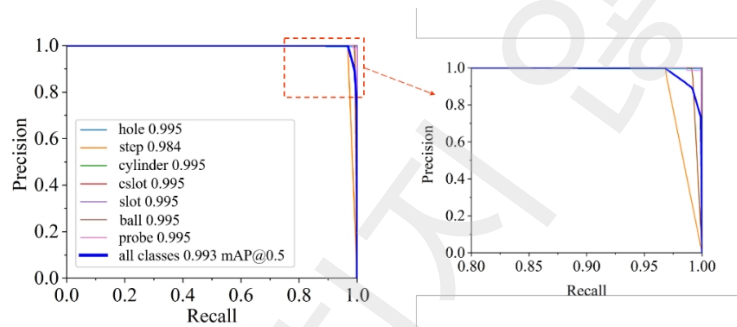


그림 5 PR 곡선

3.2 기능 일치

두 대의 산업용 카메라가 90°로 배치되어 있기 때문에 캡처된 구성 요소 보기에
서 일관된 핵심 포인트를 감지하는 것은 어렵습니다. 스케일 불변 특징 변환, 가속화된
강력한 특징, ORB와 같은 기존의 이미지 매칭 알고리즘으로는 이 두 이미지를 사용하
여 특징 매칭 작업을 완료할 수 없습니다. 카메라를 사용하여 캡처한 이미지는 원근 효
과로 인해 구성 요소의 실제 크기와 배율을 반영하지 못합니다. 따라서 역원근 변환을
사용하여 이미지에서 원근 효과를 제거하여 공작물의 직교 뷰를 생성할 수 있습니다.
두 이미지는 두 카메라로 캡처한 구성 요소의 직교 뷰를 얻기 위해 개별적으로 역원근
변환됩니다. 이 두 이미지의 특징은 구성 요소의 직교 뷰의 고유성 때문에 위치가 일치
해야 합니다. 이 연구의 특징 매칭 알고리즘은 위의 원리를 기반으로 설계되었습니다.

3.2.1 역원근 변환 모델




그림 6 역원근 변환 기하학적 광학 모델

역원근 변환은 원근 효과를 제거하여 평면에서 3차원 물체의 직교 영상을 생성하는 변환을 말합니다. 4점 역원근 변환 방법[16]은 앞뒤 4점 사이의 대응을 보정하고 좌표를 대입하여 역원근 변환 행렬을 풀어나갑니다. 그림 6은 변환의 기하학적-광학적 모델을 보여줍니다. 카메라의 광학 중심은 O 에 위치하며, 세계 좌표계에서 카메라의 이미징 표면에 있는 점 P 의 투영은 P' 입니다. 역원근 변환 후 세계 좌표계에서 P 의 좌표는 다음과 같이 유추할 수 있습니다:

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} u_{p'} \\ v_{p'} \\ 1 \end{bmatrix} \quad (1)$$

여기서 $(u_{p'}, v_{p'})$ 는 픽셀 좌표계에서 P' 의 좌표입니다. 카이제곱 좌표의 배율 불변성에 따라 $[X, Y, Z]$ 를 카이제곱 좌표로 간주하고 $a_{33}=1$, $X_{A''}=X/Z$, $Y_{A''}=Y/Z$ 로 하면 다음과 같이 구할 수 있습니다:

$$X_{A''} = \frac{a_{11}u_{p'} + a_{12}v_{p'} + a_{13}}{a_{31}u_{p'} + a_{32}v_{p'} + 1} \quad (2)$$

$$Y_{A''} = \frac{a_{21}u_{p'} + a_{22}v_{p'} + a_{23}}{a_{31}u_{p'} + a_{32}v_{p'} + 1} \quad (3)$$

$[X_{A''}, Y_{A''}]$ 의 좌표는 역원근 변환 후의 좌표입니다. 원본 이미지의 좌표점 4개와 새 이미지에서 이 4개 좌표점의 대응하는 좌표를 선택해야 8개의 방정식을 풀 수 있습

니다.

들_{11} 에서_{32} 로 미지수로 바꾸면 식 (2)-(3)에서 역원근 변환 행렬 H 를 구할 수 있습니다.

$$H = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad (4)$$

3.2.2 자동 타겟 포인트 감지

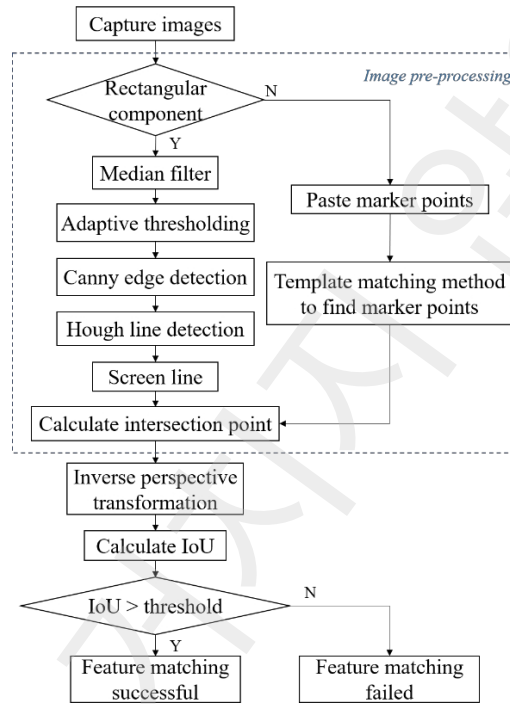




그림 7 자동 목표 지점 감지 흐름도

그림 7은 원본 이미지에서 4개의 목표점을 얻기 위한 검출 알고리즘의 흐름을 보여주고, 그림 8은 컴포넌트에 있는 4개의 목표점 $ABCD$ 를 나타냅니다. 구성 요소의 외부 윤곽은 직사각형과 직사각형이 아닌 윤곽으로 나뉩니다. 직사각형 윤곽에서는 직



(a) Rectangular component



(b) Non-rectangular component

사각형의 목표점 검출 알고리즘이 사용됩니다. 그렇지 않으면 직사각형이 아닌 모양에 대한 목표점 감지 알고리즘이 사용됩니다.

그림 8 컴포넌트의 타겟 포인트 $ABCD$ 위치

직사각형 구성 요소의 이미지 처리에는 중앙값 필터링, 적응형 임계값, 캐니 에지 감지 및 허프 라인 감지가 포함됩니다. 이미지 신호 전송 및 디코딩 프로세스가 방해받을 때 프레첼 노이즈가 발생한다는 점을 고려할 때 중앙값 필터링을 사용하면 이미지의 가장자리 정보를 더 잘 보호하면서 프레첼 노이즈를 효과적으로 제거할 수 있습니다[17]. 노이즈를 제거한 후 구성 요소의 가장자리를 정확하게 얻기 위해 전경과 배경 영역을 구분하는 데 바이너리화가 사용됩니다. 각 이미지의 전경과 배경의 그레이스케일 값은 주변 광원의 밝기와 공작물 표면에서 반사되는 빛의 정도에 따라 달라집니다. 적응형 임계값은 휘도 분포를 기반으로 다양한 이미지 영역에 대한 로컬 임계값을 계산할 수 있으며 위의 경우 구성 요소와 배경 영역을 더 잘 구분할 수 있습니다[18]. 그런 다음 캐니 에지 감지[19]와 허프 라인 감지[20]를 사용하여 이미지에서 직선을 찾습니다. 이러한 특징을 포함할 수 있는 최소 둘러싸는 직사각형 상자는 각 특징의 예측 상자의 좌표와 최소 둘러싸는 직사각형 상자의 상하좌우 네 방향에 가장 가까운 적절한 길이의 직선 네 개로 계산합니다. 또한 이 네 직선의 교차점이 목표 지점 $ABCD$ 일 수 있습니다.

직사각형이 아닌 윤곽의 경우 정사각형 레이블을 표면에 적용해야 합니다. 측정된 구성 요소를 미리 입력합니다. 라벨을 적용할 때 두 가지 조건이 충족되어야 합니다: (1) 네 개의 라벨이 직사각형 영역의 네 꼭지점에 위치해야 하고, (2) 직사각형 영역에 측정해야 하는 모든 대상 피처가 포함될 수 있어야 합니다. 템플릿 매칭 알고리즘이 라벨을 식별할 수 있도록 라벨 데이터베이스가 생성됩니다. 상관 계수 방법[21]의 템플릿 매칭은 템플릿과 이미지 영역 간의 상관 계수를 계산하여 정사각형 라벨을 식

별합니다. 상관 계수의 최대값이 임계값보다 크면 템플릿 매칭이 성공한 것으로 간주하고 목표 영역 위치를 확인합니다. 이 방법은 타겟의 이동, $\pm 180^\circ$ 회전, $\pm 50\%$ 줌 변경 등 다양한 조건에서 만족스러운 타겟 매칭을 달성할 수 있어 템플릿 매칭의 성공률과 안정성을 향상시킬 수 있습니다. 그런 다음 식별된 태그 영역은 다음과 같습니다.

를 관심 영역으로 설정하고 Harris 코너 포인트 감지[22]를 사용하여 태그의 네 개의 코너 포인트를 추출합니다. 그런 다음 네 개의 라벨의 왼쪽 상단, 오른쪽 상단, 왼쪽 하단, 오른쪽 하단 정점을 각각 역원근 변환 행렬 계산을 위한 네 개의 점 $ABCD$ 로 선택합니다.

3.2.3 매칭 알고리즘

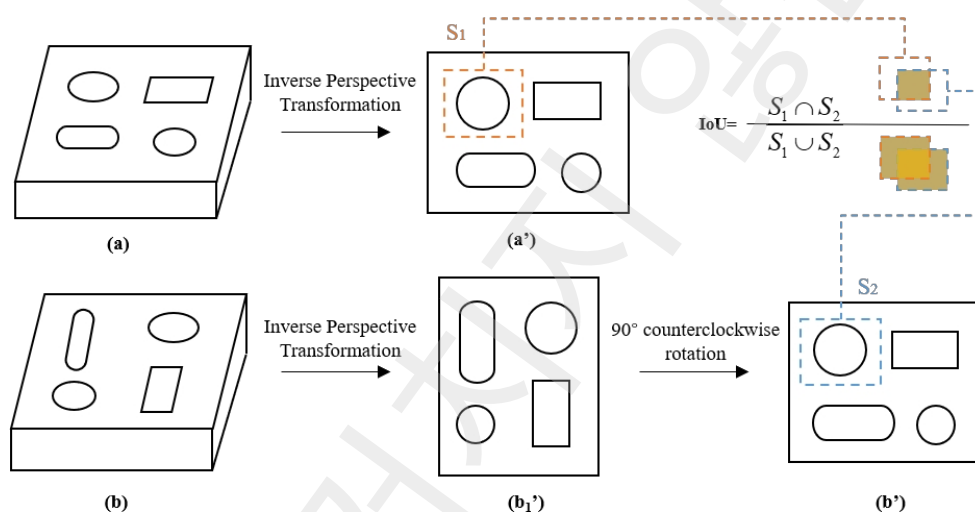


그림 9 역원근 변환을 기반으로 한 특징 매칭의 개략도

그림 9와 같이 전면 카메라 A 가 촬영한 이미지 a 는 역원근 변환을 거쳐 이미지 a' 로 변환되며, 이미지 a' 는 전면 카메라 A 가 촬영한 구성 요소의 직교 투영입니다. 오른쪽 카메라 B 가 촬영한 이미지 b 는 역원근 변환을 거쳐 이미지 b_1' 로 변환됩니다. 그런 다음 이미지 b_1' 를 시계 반대 방향으로 90° 회전하여 이미지 b' 를 얻고, 이미지 b' 는 오른쪽 카메라 B 가 촬영한 구성 요소의 직교 이미지입니다. 구성 요소의 구멍 특징 중 하나를 예로 들어 특징 검출은 이미지 a 와 b 에서 각 특징의 라벨과 예측 프레임의 좌표값을 얻습니다. 또한 이미지 a' 와 b' 에서 예측 프레임의 좌표값은 역원근 변환 행렬 H 에 따라 계산됩니다. 만약 두 개 이상의 예측 프레임이 S_1 와 겹치는 경우 레이블이 다른 예측 프레임을 먼저 제외한 다음, 그림 9의 공식에 따라 S_1 과 S_2 간의 교차 비율

IoU 를 계산합니다. 그리고 IoU의 최대값을 갖는 예측 프레임을 매칭할 피처로 선택합니다. 이 계산 결과가 임계값 $Thre$ 보다 크면, S_I 에 해당하는 피처가 매칭됩니다.

이미지 a' 는 이미지 b' 의 S_2 에 해당하는 특징과 성공적으로 일치한 것으로 간주됩니다.

특징이 일치된 후에는 각 이미지에 하나의 프로브만 있으므로 프로브 특징이 일치됩니다. 두 이미지에서 식별된 프로브는 서로 직접 매칭됩니다.

3.3 경로 계획 및 샘플링 전략

프로브를 피처의 중심 위로 안내한 후 정확한 샘플링 지점을 계산하려면 먼저 피처의 기본 파라미터를 측정해야 합니다. 피처의 대략적인 측정으로 간주되는 피처의 기본 매개변수를 계산하기 위해 피처 표면의 몇 개의 포인트만 필요합니다. 대략적인 측정이 완료되면 피처의 기본 치수 정보가 얻어지고 피처의 정확한 샘플링 포인트 분포 전략이 설계됩니다. 이 기본 치수 정보를 기반으로 샘플링 포인트의 좌표를 계산하여 프로브가 CMM의 3축 모션을 따라 피처를 측정하도록 구동합니다.

일반적인 피처는 회전하는 바디 피처와 회전하지 않는 바디 피처의 두 가지 범주로 나뉩니다. 회전하는 바디 피처는 구멍, 원통 또는 공과 같이 닫힌 회전 표면으로 둘러싸인 기하학적 피처입니다. 비회전 바디 피처는 사각형 슬롯, 원형 슬롯, 계단 등 회전하는 바디 피처 이외의 피처입니다.

3.3.1 대략적인 측정 경로 계획

3.3.1.1 회전하는 바디 피처에 대한 대략적인 측정 경로 계획




그림 10 구멍의 대략적인 측정 경로

그림 10은 구멍의 대략적인 측정 경로를 보여줍니다. 프로브가 안내된 후 구멍이 위치한 평면의 점 A가 경로 1-2를 따라 먼저 측정됩니다.

를 구멍의 중앙 위에 위치시키면, 경로 1에 의해 이동한 거리 x 는 이미지의 정보로부터


다음과 같이 계산됩니다:

$$x = K \times (u_{\text{특징}0} - u_{o\text{-tip}}), \quad (5)$$

여기서 K 는 세계 좌표계에서의 실제 거리와 픽셀 좌표계에서의 픽셀 사이의 비율, $u_{\text{feature}0}$ 은 특징 감지 프레임의 좌측 하단 모서리 좌표, $u_{o\text{-tip}}$ 은 u 축 방향의 프로브 중심 좌표 값입니다.

그런 다음 구멍은 경로 3-4를 따라 초기 중심 위치로 돌아갑니다. 프로브가 구멍의 바닥에 닿을 때까지 가라앉아 좌표점 O_1 를 얻은 다음 O_2 까지 거리를 상승하고 경로 7-11을 따라 O_2 의 단면에 있는 네 점 $BCDE$ 를 측정합니다. 깊이 h_{hole} 는 z 축의 A

와 O_1 사이의 거리에서 계산하고 구멍의 직경 d_{hole} 은 네 점 $BCDE$ 를 끼워 맞춰 구합



(a) 실린더

(b) 공

그림 11 실린더와 볼의 대략적인 측정 경로

그림 11(a)는 원통의 대략적인 측정 경로를 보여줍니다. 먼저 프로브가 원통의 중심 위로 안내된 후 프로브가 가라앉아 원통의 윗면에 있는 점 A 를 측정합니다. 그런 다음 원통의 바닥면이 위치한 표면의 점 B 를 경로 2-4를 따라 측정하고, 경로 3에 의해 이동한 거리 x 는 식(5)에 의해 계산됩니다. 그런 다음 프로브가 상승하고 현재 프로브

의 높이에서 원통의 원형 부분에 있는 네 점 $CDEF$ 가 측정되며, 그 경로는 6-19입니다.

경로 8, 9, 12, 13, 16, 17의 거리 계산은 경로 3의 거리 계산과 동일합니다. 실린더 h 원

통의 높이는 Z 축의 A 와 B 사이의 거리로 계산되고 실린더 $d_{\text{원통}}$ 직경은 다음과 같습니

다.

의 네 점을 맞춰서 얻은 값입니다. 그림 11(b)는 공의 대략적인 측정 경로를 보여주며, 공의 대략적인 측정 경로는 원통의 그것과 유사합니다.

3.3.1.2 회전하지 않는 신체 형상에 대한 대략적인 측정 경로 계획




그림 12 슬롯 및 스텝의 대략적인 측정 경로

그림 12(a)는 슬롯의 대략적인 측정 경로를 보여줍니다. 전체 경로는 구멍의 거친 측정 경로와 동일합니다. 슬롯의 깊이 h 는 Z축의 A와 B 사이의 거리에서 계산되며, 슬롯의 길이 l 은 다음과 같습니다:

$$l = l_{CE} \cdot \cos\theta, \quad (6)$$

여기서 l_{CE} 은 X축 방향에서 CE의 두 점 사이의 거리이고 θ 는 이미지 처리를 통해 얻은 CMM의 X축에 대한 정사각형 슬롯의 기울기 각도입니다. 마찬가지로 정사각형 슬롯의 너비 w 는 다음과 같습니다:

$$w = l_{DF} \cdot \cos\theta, \quad (7)$$

여기서 l_{DF} 은 Y축 방향에서 DF의 두 점 사이의 거리입니다.

그림 12(b)는 스텝의 대략적인 측정 경로를 보여줍니다. 전체 경로는 원통의 대략적인 측정 경로와 동일합니다. 스텝의 높이 h , 길이 l , 너비 w 는 슬롯과 동일합니다.

3.3.2 샘플링 포인트의 정확한 분포

3.3.2.1 회전하는 바디 피처를 위한 샘플링 포인트의 정확한 분포




그림 13 열의 샘플링 지점 분포

그림 13은 기둥 표면의 정확한 측정을 위한 샘플링 포인트의 분포를 보여주며, 샘플링 포인트 분포 법칙은 식물 뿌리줄기 분포 모델을 따릅니다. 이 모델은 식물 뿌리줄기의 잎 분포 법칙을 사용하여 기둥 표면에서 샘플링 포인트가 균일하게 엇갈리게 분포되도록 합니다[23]. 샘플링 포인트의 수는 n 으로 설정되며, 기둥 표면의 높이 h 와 직경 d 는 대략적인 측정을 통해 계산되며, CMM 좌표계에서 재 샘플링 포인트의 좌표값은 필로데스 분포 모델에 의해 계산할 수 있습니다 [24]:

$$\begin{cases} x = \frac{d}{2} \cdot \cos\theta_i \\ y = \frac{d}{2} \cdot \sin\theta_i \\ z = h \cdot \frac{i}{n} \end{cases} \quad (8)$$

여기서 θ_i 는 재 샘플링 지점의 선과 점 O 사이의 각도와

X 축으로, 방정식 (9)에 의해 계산됩니다.

$$\theta_i = 137.508^\circ \cdot i$$




그림 14 공의

그림 14는 공의 정확한 샘플링 포인트 분포를 보여줍니다. 공의 샘플링 포인트는 공의 표면에 가능한 한 고르게 분포되어야 합니다. 공의 노출된 평면의 높이 h 와 직경 d 는 대략적인 측정 후 얻습니다. $h > d/2$ 이면 공의 상반부만 측정하고 $h = d/2$ 로 합니다. 공의 상반부는 원형 각도 θ 에 따라 4개의 동일한 층으로 나뉘며, 짝 층의 대응하는 원형 각도 α_i 는 다음과 같습니다:


$$\begin{cases} \theta = \arccos \frac{D - 2h}{d} \\ \alpha_i = \frac{\theta}{4} \end{cases} \quad (10)$$

인접한 두 레이어의 샘플링 포인트가 엇갈리게 배치되어 있어 구의 샘플링 포인트가 균일하게 분포합니다. 각 샘플링 포인트의 좌표는 다음과 같이 계산됩니다:

$$\begin{cases} x_i = \frac{d}{2} \cdot \sin \alpha_i \cdot \cos \beta_j \\ y_i = \frac{d}{2} \cdot \sin \alpha_i \cdot \sin \beta_j \\ z_i = \frac{d}{2} \cdot \cos \alpha_i \\ \beta_j = \frac{2\pi j}{n} \end{cases}, \quad (11)$$

여기서 i 는 포인트가 위치한 레이어 수, j 는 짝 레이어의 샘플링 포인트 중 j 번째 샘플링 포인트, α_i 는 레이어 i 의 해당 원형 각도, β_j 는 레이어 i 의 j 번째 포인트와 양수 X 방향의 좌표축 사이의 각도, n 은 레이어의 샘플링 포인트 수입니다.

3.3.2.2 회전하지 않는 신체 특징에 대한 샘플링 포인트의 정확한 분포



(a) 슬롯 샘플링 포인트 분포 (b) 샘플링 포인트의 Z 방향 투영


배포

그림 15 슬롯의 샘플링 포인트 분포

그림 15는 슬롯 샘플링 포인트의 분포를 보여주며, 균일 분포의 샘플링 전략을 채택하고 있습니다. 대략적인 측정 결과에서 깊이 h ,

슬롯의 길이 L 과 너비 W 를 계산할 수 있습니다. 슬롯의 측정 레이어 수 m 과 레이어당 측정 포인트 수 n 을 설정하고, 측정 포인트는 각 면에 균등하게 분포하며, 포인트는 면에 동일한 거리에 배치됩니다. 각 면의 가장자리 측정점과 면의 가장자리 사이의 거리를 a 로 설정하고 AB 면의 j 번째 레이어에 있는 점 샘플링 포인트의 좌표는 식 (12)에 의해 계산됩니다. 다른 면의 샘플링 포인트 좌표도 같은 방식으로 계산됩니다.

$$\begin{cases} x = \frac{l}{2} + a + \frac{4l}{n} \cdot i \\ y = \frac{w}{2} + \frac{4w}{n} \cdot j \\ z = A + \frac{H}{m} \cdot J \end{cases} \quad (12)$$



(a) 단계 샘플링 포인트 분포 (b) Z 방향 투영의 샘플링 포인트 분포

그림 16 단계별 샘플링 포인트 분포

그림 16(a)는 스텝의 샘플링 포인트 분포를 보여줍니다. S자형 경로를 사용하여 범프의 5개 평면에 동일한 간격으로 점을 배치하면 샘플링 점 분포의 균일성을 보장할 뿐만 아니라 각 층의 샘플링 점이 서로 인터리빙되어 평면의 오류 상황을 더 잘 반영할 수 있습니다. 각 평면의 샘플링 포인트는 그림 16(b)와 같이 삼각 곡선 위에 분포되어 있습니다. 점의 좌표는 계단의 높이 h , 길이 l , 폭 w 를 기준으로 계산할 수 있으며, 식 (13)은 상부 표면의 샘플링 점의 좌표입니다. n 은 평면의 샘플링 점 수이고 a 는 가장자리 측정점과 면의 가장자리 사이의 거리입니다. 스텝의 다른 표면에 있는 샘플링 포인

트의 좌표도 같은 방식으로 계산됩니다.

$$\begin{cases} x = \frac{l}{i} \\ y = \left(\frac{w}{2} \right)^p \sin \left(\frac{5\pi x}{L \times 2A} \right) \\ z_i = h \end{cases} \quad (13)$$

4. 실험 및 결과




그림 17 CMM 지능형 측정 시스템의 물리적 구성도

그림 17은 CMM 지능형 측정 시스템의 물리적 다이어그램을 보여줍니다. 이 시스템은 1 μ m의 분해능을 가진 각 방향의 선형 모터(57BYGH250B)와 래스터 스케일(Renishaw RH100 \times 30.05A)이 장착된 홈메이드 CMM에 장착되어 있습니다. 선형 모터는 모션 제어 카드(LeadShine DMC3000)의 펄스 신호로 제어되고 드라이버(LeadShine DM542)에 의해 구동됩니다. 트리거 반복성이 0.5 μ m이고 분해능이 다음과 같은 가정용 산업용 프로브입니다.

0.5 μ m는 CMM의 Z축에 장착되며, 프로브의 프로브 팁은 직경 1mm 루비볼 Renishaw 프로브 팁입니다. 프로브에서 생성된 트리거 신호는 획득 카드(NI PCI-6259)에 의해 기록되어 PC로 전송됩니다. 선택한 산업용 카메라(MER-301-125U3M)에는 두 개의 렌즈(컴퓨터 M1224-MPW2)가 각각 CMM의 전면과 우측에 사용됩니다. 카메라 이미지 해상도는 2048 \times 1536이고 픽셀 크기는 3.45 μ m \times 3.45 μ m입니다.

니다. 링 광원(LED-A5067)은 전체 시스템에 밝기를 제공하기 위해 CMM의 왼쪽 후면에 배치됩니다.




그림 18 이미지 a, b의 탐지 결과

이 실험에서는 계단, 원통, 구멍, 씨슬롯 특징이 있는 물체를 측정할 구성 요소로 사용합니다. 먼저 구성 요소의 위치를 조정하고 구성 요소와 프로브가 동시에 카메라 시야에 선명하게 나타나도록 프로브를 이동합니다. 전면 카메라 A와 오른쪽 카메라 B는 현재 이미지 A와 B를 촬영하여 학습된 특징 감지 모델에 입력합니다. 그림 18은 감지 결과를 보여줍니다. 표 4에는 특징 레이블과 좌표가 나와 있습니다.

이미지 좌표계에서 감지 프레임의 값입니다.

표 4 탐지 프레임의 특징 레이블 및 좌표 값							
이미지	라벨	아니요	자신감	감지 프레임/픽셀의 좌표값			
				A	B	C	D
이미지 a	프로브	0	0.85	(1093,537)	(1205,537)	(1093,731)	(1205,731)
	단계	1	0.95	(1080,791)	(1264,791)	(1080,983)	(1264,983)
	실린더	2	0.95	(814,796)	(924,796)	(814,959)	(924,959)
	cslot	3	0.92	(768,970)	(970,970)	(768,1057)	(970,1057)
	구멍	4	0.96	(1098,1011)	(1233,1011)	(1098,1110)	(1233,1110)
	구멍	5	0.94	(901,1080)	(1064,1080)	(901,1197)	(1064,1197)
이미지 b	구멍	0	0.96	(1047,1054)	(1182,1054)	(1047,1158)	(1182,1158)
	구멍	1	0.94	(916,942)	(1074,942)	(916,1057)	(1074,1057)
	cslot	2	0.92	(1123,865)	(1240,865)	(1123,1000)	(1240,1000)
	실린더	3	0.92	(1277,798)	(1384,798)	(1277,982)	(1384,982)
	단계	4	0.90	(1295,944)	(1415,944)	(1295,1187)	(1415,1187)
	프로브	5	0.84	(898,499)	(1000,499)	(898,688)	(1000,688)

그림 19 역원근 변환 결과 이미지




그림 20 좌표 변환 후 예측 프레임의 개략도

의 역 관점 변환 매트릭스 H 의 이미지 a 입니다:

$$H = \begin{pmatrix} 5.7653 & 0.5300 & -4879.3187 \\ 0.0819 & 7.5790 & -6603.5477 \\ 0.0176 & 0.0006 & 1 \end{pmatrix}$$

의 변환 행렬의 image b 입니다:

$$Hb = \begin{pmatrix} 0.1162 & 10.5324 & -9297.7151 \\ -4.4894 & 0 & 0 \\ 0.0093 & 0.0007 & 1 \end{pmatrix}$$

를 클릭하고 그림 19는 변환 결과를 보여줍니다. 그림 19

변환된 예측 프레임의 좌표는 행렬 H 와 표 4의 예측 프레임 좌표에 따라 계산됩니다.

예측 프레임이 설정된 이미지 크기 이상으로 변환되면 새로운 이미지 경계가 예측 프레임 경계로 사용됩니다. 그림 20은 모식도를 보여줍니다. 특징 매칭 알고리즘에서 언급한 스크리닝 원리에 따라 특징 레이블이 같고 겹치는 면적이 가장 큰 예측 프레임을 찾습니다. IoU가 계산되고 IoU

임계값을 0.3으로 설정합니다. 표 5는 매칭 결과를 보여줍니다.

표 5 기능 일치 결과

이미지 a		이미지 b		겹치는 영역 (픽셀*픽셀)	IoU	결과 기능 매칭
아	라벨	아니	라벨			
니		요.				
요.						
0	프로브	5	프로브	-	-	성공
1	단계	4	단계	199409.6869	0.3354	성공
2	실린더	3	실린더	114523.2569	0.4166	성공
3	cslot	2	cslot	223719.7623	0.7560	성공
4	구멍	0	구멍	191612.4563	0.8352	성공

지능형 방법의 핵심은 감지 및 매칭 결과의 정확성입니다. 구성 요소의 각 특징을 정확하게 감지하고 일치시킬 수 있다면 나중에 특징 측정을 성공적으로 완료할 수 있

습니다. 구성 요소 배치, 구성 요소 유형, 광원 밝기, 카메라 촬영 각도 등 알고리즘의 성공률에 영향을 미칠 수 있는 요소를 변경하여 테스트 세트를 만들어 감지 및 매칭 알고리즘의 성공률을 검증합니다. 숫자

이 테스트 세트의 샘플 수는 그림 21과 같이 250개입니다. 테스트 세트 이미지를 알고리즘에 입력하여 탐지 및 매칭을 수행했으며, 표 6은 그 결과의 성공률을 나타냅니다.

표 6을 보면 특징의 가려진 정도가 특징 매칭 결과에 큰 영향을 미친다는 것을 알 수 있습니다. 특징 매칭의 성공률에 대한 가려진 비율의 영향을 확인하기 위해 구멍을 물체로 사용하고, 프로브 위치를 전면 카메라 시야에서 이동시켜 시야에서 구멍의 가려진 정도가 달라지도록 합니다. 구멍 면적에 대한 오클루전 영역의 비율은 10%-100%이며, 순차적으로 5%씩 증가합니다. 또한 두 카메라 모두 사진을 촬영하고 특징 매칭을 수행합니다. 매칭 결과에 미치는 영향을 확인하기 위해 IoU 임계값을 변경합니다. 실험 결과, 피처가 가려지지 않은 영역의 비율이 IoU 임계값보다 클 때 성공적으로 매칭할 수 있는 것으로 나타났습니다. 따라서 카메라 시야에 있는 개별 피처는 측정 중에 가능한 한 방해받지 않도록 유지해야 합니다.




그림 21 탐지 및 매칭 테스트 세트 샘플 표 6 탐지 및 매칭 결과의 성공률

영향 요인	이미지 수	탐지 성공률	매칭 성공률
구성 요소 배치	50	100%	100%
구성 요소 유형	50	100%	100%
광원 밝기	50	100%	100%

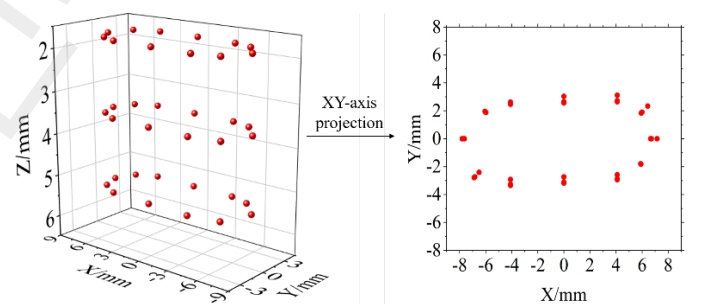
카메라 촬영 각도	50	100%	100%
기능의 정도	50	100%	92%
오כל루전			

좌표계 xOy 에서 각 특징점의 좌표(x, y)는 이미지 a 와 b 에서 프로브 팁과 각 특징점 사이의 상대 픽셀 차이로부터 얻습니다. 전체 측정 과정은 프로브 팁의 TSP로 간주되며 개미 군집 알고리즘은 특징점의 최적 측정 순서를 계획하는 데 사용됩니다. 초기화 알고리즘 파라미터는 개미 수를 30, 개미 선택 경로에서 페로몬의 중요도를 $\alpha = 2$, 개미 선택 경로에서 휴리스틱 인자의 중요도를 $\beta = 5$, 초기 순간 페로몬의 농도를 $\tau = 0.1$, 최대 반복 횟수를 500으로 설정합니다. 최적의 탐지 순서는 오른쪽 카메라 이미지에서 식별된 피쳐 라벨 일련 번호를 기준으로 5-3-2-1-4로 계산됩니다.

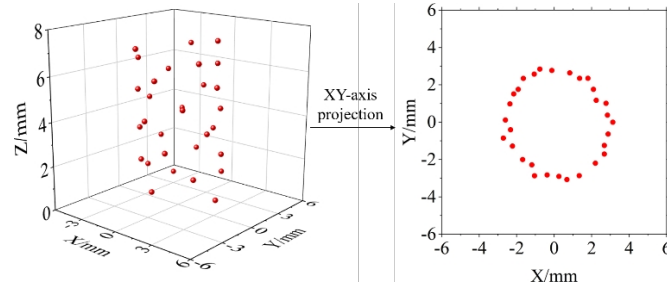
안내 알고리즘은 측정 순서대로 프로브 팁을 특징 중심에 더 가깝게 안내하는 데 사용됩니다. 피처를 대략적으로 먼저 측정하고 얻은 정보를 사용하여 정확한 샘플링을 위한 좌표점을 계산한 다음 피처를 다시 측정합니다. 그림 22는 피처의 정확한 샘플링 포인트 맵을 보여줍니다. 그런 다음 샘플링 포인트의 좌표를 맞춰 구멍의 직경, 원통의 직경, 슬롯의 길이와 너비 등 피처의 기본 파라미터를 얻을 수 있습니다.



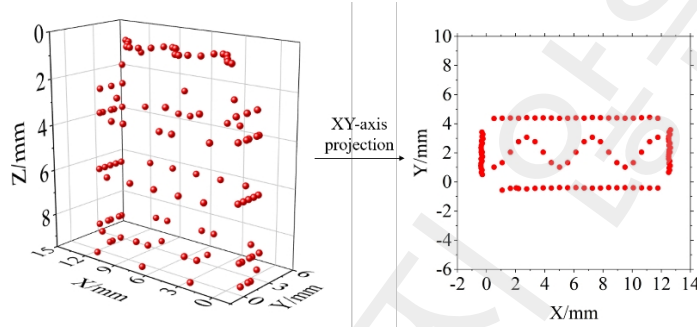
(a) 구멍의 측정 결과



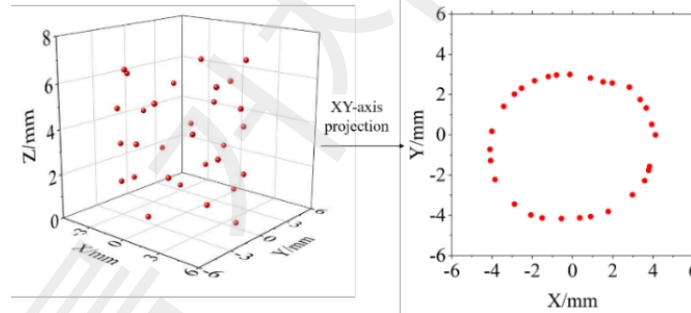
(b) *cslot*의 측정 결과



(c) 실린더의 측정 결과



(d) 단계별 측정 결과



(e) 구멍의 측정 결과₂

그림 22 정확한 샘플링 포인트 맵

5. 결론

본 연구에서는 전형적인 특징을 자동으로 측정하는 CMM의 지능형 측정 방법과 시스템을 제안했습니다. 여러 개의 전형적인 특징을 가진 부품의 지능형 측정 실험을 통해 제안한 방법과 시스템의 정확성과 효율성을 검증했습니다. 카메라 시야에 피처가 가려지지 않을 때 100% 측정이 완료됩니다. 또한, 오클루전 발생 시 피처가 가려지지 않은 영역의 비율이 일치하는 IoU 임계값보다 클 때 측정의 정확성을 보장할 수 있습니다. 이 방법은 CAD가 필요하지 않으며 지능, 고효율, 저비용의 장점이 있습니다.

이 시스템은 범용성이 뛰어나 다양한 유형의 CMM에 설치할 수 있습니다. 향후

연구를 통해 딥러닝 알고리즘을 사용하여 복잡한 유형의 특징을 보다 지능적으로 측정할 수 있는 방법을 개발할 예정입니다.

6. 참조

- [1] 나스르 E, 캄라니 A K. CAD 시스템에서 제조 특징을 추출하는 새로운 방법론[J]. 컴퓨터 및 산업 공학, 2006, 51(3):389-415.
- [2] 기계 CAD 모델을위한 기본 기반 3D 분할 알고리즘[J]. 컴퓨터 지원 기하학 설계, 2017, 52-53:231-246.
- [3] 하세 V J, 발레라오 Y J, 베르마 S 외. 패턴 매칭을 이용한 CAD 메쉬 모델의 블렌드 인식[C]. 제1회 기계공학 및 나노기술 발전에 관한 국제 컨퍼런스(ICAMEN), 2019, 2148:030029.
- [4] 조 M W, 이 H, 윤 G S 외. 좌표 측정기를 위한 특징 기반 검사 계획 시스템[J]. 국제 첨단 제조 기술 저널, 2005(9/10):26.
- [5] Durrant-Whyte H F. 센서 모델 및 다중 센서 통합[J]. 국제 로봇 연구 저널, 1988, 7(6):97-113.
- [6] 브래들리 C, 찬 V. 리버스 엔지니어링에 대한 보완적인 센서 접근법[J]. 제조 과학 및 공학 저널, 2001, 123(1):74-82.
- [7] 레이저 스캐너와 촉각 프로브의 조합을 사용한 자동화된 치수 검사 계획[J]. 측정, 2012, 45(5):1057-1066.
- [8] 황윤바오, 샤오팡. 3 차원 포인트 및 영역 센서 통합에 대한 동적 감지 및 모델링 접근 방식[J]. 제조 과학 및 공학 저널, 2007, 129(3):623-635.
- [9] 다중 센서 데이터 융합을 통한 복잡한 형상의 신속하고 정밀한 리버스 엔지니어

링[J]. IEEE Access, 2019, 7:165793- 165813.

- [10] Lu K, Wang W. 리버스 엔지니어링에서 자유형 표면의 빠르고 정밀한 디지털화를 위한 다중 센서 접근 방식[J]. 국제 첨단 제조 기술 저널, 2015, 79(9-12):1983-1994.

- [11] Z.Y. Cheng, Luan He, Yuan Sun 등. CMM 프로브 팁을 직경이 1밀리미터 미만이고 종횡비가 높은 구멍으로 자동으로 이동하는 새로운 방법 및 시스템[J]. Instrum. , 2021, 16(6): 06042.
- [12] Z. Y. Cheng, Y. Sun, H. Luan, H. -L. Li, Q. -S. Pan and R. J. Li. CMM 스타일러스를 마이크로 홀로 자동 이동하기 위한 자체 보정 비전 방법 및 시스템. IEEE 센서 저널, 2022, 22(4): 3579-3584.
- [13] 레드몬 J, 디발라 S, 기르식 R 등. 한 번만 보면 됩니다: 통합된 실시간 물체 감지 [C]. 컴퓨터 비전 및 패턴 인식에 관한 IEEE 컨퍼런스 프로시딩. 2016, 779-788.
- [14] 조처, G., 스토크, A., 보로벡, J. 울트라알리틱/올로프5. 온라인에서 사용 가능: <https://github.com/-ultralytics/yolov5> (2021년 6월 25일에 액세스).
- [15] Jing Y, Ren Y, Liu Y, Wang D, Yu L.. 개선 된 YOLOv5를 기반으로 지진으로 인한 피해 주택 자동 추출 : 양비 사례 연구[J]. 2022, 14(2):382.
- [16] A. Sun, Y. Wei, Y. Zhou, J. Wang, Y. Liu, 호모그래피 변환에 기반한 단일 이미지의 3D 추정[C]. 2022 IEEE 제6회 정보 기술 및 메카트로닉스 엔지니어링 컨퍼런스(ITOEC), 충칭, 중국, 2022, 727-732.
- [17] 조지 G, 옴멘 R M, 셸리 S 외. 디지털 이미지에서 임펄스 노이즈 제거를 위한 다양한 중앙값 필터링 기법에 대한 조사[C]. 2018 신흥 디바이스 및 스마트 시스템 컨퍼런스(ICEDSS). IEEE, 2018.
- [18] Chan F, Lam F K. 변형 방법에 의한 적응형 임계값[J]. IEEE 트랜스 이미지 프로세스, 1998, 7(3):468-473.

[19] C. Wu 외. 반복 그라디언트 필터를 사용한 개선된 캐니 에지 검출 알고리즘[C].

2022 제6회 국제 이미징, 신호 처리 및 통신 컨퍼런스(ICISPC), 구마모토, 일본,

2022, 16-21.

[20] 빠른 선과 원 검출을 위한 허우 변환 기반의 새로운 방법[C]. 2015 제8회 의생명

공학 및 정보학 국제 컨퍼런스(BMEI). IEEE, 2015, 52-56.

- [21] Y. 코니시, Y. 코타케, Y. 이지리, 및 M. 카와데. 방향성 그라데이션에 기반한 빠르고 정확한 템플릿 매칭[C]. in Proc. Conf. Comput. Vis., 2012, 7585:607-610.
- [22] 한 S, 유 W, 양 H 외. 해리스 기반의 개선된 코너 감지 알고리즘[C]. 2018 중국 자동화 학회(CAC), 2018, 1575-1580.
- [23] Chen B. 브레이징 다이아몬드 연삭 디스크의 연마 지형 최적 및 배열 기술[J]. 국제 내화 금속 및 경질 재료 저널, 2021, 95(1):105455.
- [24] Yeatts F R. 해바라기 머리 모양의 성장 제어 모델[J]. 수학 생명과학, 2004, 187(2):205-221.